

# 语义架构究竟需要多复杂？

面向证据约束数据集 Schema 归纳的因果可控 A/B/C/D 实验协议

盲测前匿名技术报告

作者与机构信息将在协议冻结时绑定

2026 年 7 月 16 日

## 摘要

本研究考察一个以“输入数据集，输出 **deterministic-based schema**”为产品边界的系统中的语义组件。物理 **Schema** 始终由确定性解析器拥有；语言模型只能针对已有字段、基于已给证据提出属性级语义补充。我们将历史上碎片化的语义流水线收敛为四个固定条件：**A** 为纯确定性系统；**B** 在确定性抽取后至多增加一次 **dataset-level** 语义调用；**C** 精确复用 **B** 的同一响应，再执行确定性的证据身份、字段相关性和冲突检查；**D** 保留历史 **per-field/manual-group** 调度与“非空证据字符串即可合并”的行为。

当前阶段的贡献是可审计的实验协议和经过验证的 **measurement harness**，而不是某个架构获胜的结论。九个合成开发案例中，只有两个存在 **dataset-level** 语义机会，其中一个目标不在 **gold** 中，因此所有架构间比较都被正确标记为不可比较。较小的 **Qwen3.5 9B** 在该集合中没有增加可接受、可评分的语义 **claim**；观测到的 **B-C** 零差异是不充分信息，而非零效应。对抗测试验证了调用边界、**replay**、证据、弃权、适用性、**unsupported claim** 与 **AURC** 等不变量。

随后进行的 **backend qualification** 首先暴露了 **runtime** 和测量缺陷：8,192 context 且 **thinking** 实际开启的 **Qwen3.6-27B** 运行被作废。在修复 **replay/telemetry provenance**、关闭 **thinking** 并加载 16,384 context 后，同一 **Q4\_K\_M** 模型在八个非盲校准数据集、74 个语义目标上通过全部预声明 **operational criteria**。该结果只证明执行兼容性。**dataset-level** 推理和 **deterministic verification** 的真实因果贡献仍必须由两名独立标注者完成 **gold** 后，在冻结盲测中估计。本文为 **blind-freeze provenance** 保留了显式占位区。

**关键词：**语义 Schema 归纳；选择性预测；证据约束；确定性验证；**replay identity**；模型能力债务；数据集元数据。

## 1 引言

数据集 Schema 归纳包含两类不同的认识论问题。字段名、存储类型、**shape**、**group** 和显式 **attribute** 是字节与格式标准的属性，应由 **parser** 判定；一个字段究竟是 **identifier**、**measurement**、**time axis** 还是某类领域量，则常常需要跨字段和文档的语义整合。若把两者都当作自由文本生成，便难以区分“听起来合理的元数据”和 **schema truth**；若全部交给确定性规则，则会丢失真正需要上下文推理的信息。

本项目因此保留严格的 **authority boundary**：确定性 **extractor** 拥有 **canonical physical structure**；语义组件只能对已存在字段提出 **claim**，只能引用输入 **evidence catalog** 中的 **ID**，

证据不足时必须 **abstain**。这与可审计派生关系的 **provenance** 模型 [7]、基于证据的模型修订 [1]，以及以 **coverage** 换取低 **risk** 的 **selective prediction** [3] 一致。

历史实现包含 **per-field** 调用、**manual grouping**、重复 **free-JSON/schema** 尝试和多层 **merge rule**。这些复杂度中的一部分，可能只是早期小模型无法整合 **dataset-level context** 时的补偿。本文将“为旧模型能力限制引入、但在限制减弱后仍残留的复杂度”称为**模型能力债务 (Model Capability Debt)**。研究目标并非最大化新模型使用，而是找出在不破坏 **trust boundary** 的前提下所需的最小架构。

研究问题为：

**RQ1:** 相比纯确定性抽取，一次 **dataset-level** 语义推理调用增加了什么？

**RQ2:** 在语义响应完全相同的条件下，**deterministic verification** 改变了什么？

**RQ3:** 与历史 **per-field** 系统相比，最小 **hybrid** 是否能以更少语义调用维持或改善 **trustworthiness**？

在 **blind gold** 尚未解封的当前阶段，三个问题都没有有效的 **effect estimate**。已完成工作的价值，是保证未来的估计具有可解释的因果含义，并明确尚缺哪些证据。

## 2 问题定义与产品边界

产品级映射为

`dataset file(s) → deterministic canonical schema ⊕ optional semantic claim ledger.`

确定性 **Schema** 本身是完整、可独立交付的输出。语义层只是可选 **overlay**，不得创造字段、静默覆盖更强的 **deterministic claim**，也不得把置信度当作证据。

对字段路径  $f$ 、属性  $p$  和候选值  $v$ ，语义 **claim** 表示为

$$c = (f, p, v, E, s, d),$$

其中  $E$  是 **evidence ID** 集合， $s$  只用于 **risk-coverage** 排序， $d$  是最终 **decision**。正确性与 **confidence** 分离：高置信 **claim** 仍可能 **unsupported**，低置信 **claim** 也可能有可追溯证据。**decision** 包括 **accepted**、**rejected** 与 **abstained**；**verification state** 区分 **deterministic agreement**、**evidence-grounded support**、**contradiction**、**conflict** 和 **unsupported**。

**Gold applicability** 同样显式区分：(i) 适用且存在值；(ii) 适用但真实未知；(iii) 不适用；(iv) 位于 **open-world gold scope** 之外。这样既不会把 **abstention** 偷换成错误的 **accepted prediction**，也不会把 **gold** 缺失误判为 **N/A**。

## 3 第一性原理架构审计

审计将 **essential complexity** 与 **accidental complexity** 分开。**Parser** 对物理事实的权威、结构化 **abstention**、属性级 **provenance** 和显式 **conflict state** 是 **essential**，因为它们编码 **trust boundary**。**per-field prompt fragmentation**、**manual grouping**、重复

free-JSON/schema 尝试和冗余数据变换，在被实验证明有价值之前都属于历史复杂度。Rigid schema 在能让 failure observable 时仍然有用，但不能仅因它能迫使模型给出偏好答案而保留。

审计给出的保守规则是：只有 replay-controlled experiment 证明简化方案不差于旧方案后，才删除旧语义 orchestration。这避免了把旧的模型能力债务替换成新的模型依赖。

## 4 四个固定架构 Variant

表 1: 冻结的语义架构。研究中不允许加入第五个 variant。

| ID | 名称                | 语义                                                                                                  | 语义生成调用        |
|----|-------------------|-----------------------------------------------------------------------------------------------------|---------------|
| A  | 纯确定性              | 输出 parser-owned schema 与 deterministic claims；不使用语义模型。                                              | 0             |
| B  | Dataset reasoner  | 确定性抽取后，对所有未解决目标至多生成一个 dataset-level 语义响应。                                                           | 每数据集 $\leq 1$ |
| C  | Replay + verifier | 消费 B 的精确响应；检查 evidence identity、field relevance、deterministic contradiction 和 cross-claim conflict。 | 0 个新调用        |
| D  | Legacy pipeline   | 保留 per-field/manual-group、温度 0.2、free-JSON 后 schema fallback，以及历史非空证据 merge rule。                   | 可变，通常较多       |

B-C 是最干净的因果干预。Memoizing backend 对完整请求做 fingerprint，将 B 的 raw response 与 SHA-256 identity 原样提供给 C。若 C 新生成响应、缺失 replay 或消费不同 hash，则比较失效。C 的 verification 是确定性的，但不声称验证 semantic entailment：存在且 field-relevant 的 citation 只证明可追溯支持，不证明事实真值。

## 5 评测方法

令  $V$  为 applicable-value slots， $P$  为其中被接受的 predictions， $K \subseteq P$  为正确的 accepted predictions，则

$$\text{end-to-end accuracy} = \frac{|K|}{|V|}, \quad (1)$$

$$\text{coverage} = \frac{|P|}{|V|}, \quad (2)$$

$$\text{selective risk} = 1 - \frac{|K|}{|P|}. \quad (3)$$

当  $P$  为空时，selective accuracy/risk 记为未定义，而非强制记零。Abstention 会降低 end-to-end accuracy 与 coverage，但不进入 conditional selective-risk denominator。Confidence

dence 仅用于按完整 tie group 排序, 构造 right-continuous risk-coverage curve。AURC 只对 achieved coverage 积分; 当不同属性的 confidence scale 不同时, 优先报告 per-property curve。

Unsupported claim rate 只在模型提出或接受的 claim 上计算, 不能被大量 deterministic claim 稀释。资源统计区分 generated calls、reused upstream calls 与 effective architecture cost。当任一侧 partial、replay identity 失败、必要 gold 缺失或 semantic target 位于评分设计外时, pairwise comparison 必须标记 non-comparable。

5.1 Evaluator 的对抗验证

当前 variant 与 backend qualification 的 focused suites 共包含 53 个测试, 整个项目共有 332 个通过的测试。覆盖 nonexistent/irrelevant/wrong-span/contradictory/empty evidence, confidence 0 与 1, malformed/partial output, duplicate 与 conflicting claims, applicable unknown 与 N/A, missing/mismatched replay, hidden retry, timeout, zero/all accepted, 以及 confidence ties。额外 regression 保护 failure replay identity、per-call context accounting、legacy fallback telemetry 与 partial-D provenance。

表 2: 由代码和测试强制执行的核心因果不变量。

| 不变量              | 强制行为                                                                 |
|------------------|----------------------------------------------------------------------|
| A 调用边界           | 永远为零模型调用。                                                            |
| B 调用边界           | 每数据集至多一次 dataset-level generation; 隐藏 retry 会令 run partial。          |
| C replay 边界      | 零 generation, 且必须与 B raw-response hash 完全一致, 包括 malformed replay。    |
| 证据边界             | 缺失、空、跨字段或错误 span 的证据不能 verify claim。                                 |
| Confidence 边界    | Confidence 永远不能推出 verification。                                      |
| Applicability 边界 | N/A、applicable unknown、applicable value 与 outside-scope 分开。          |
| Comparability 边界 | Partial execution、gold coverage 缺失或 replay failure 会抑制 causal delta。 |
| Legacy fidelity  | 历史调度和 merge 行为不变; 所有 attempt 都被测量。                                   |

6 合成开发实验

Development manifest 包含 9 个由开发者构造的 regression cases, 覆盖 CSV、HDF5 与 time-series。它不是随机样本, 不能提供 external validity。仅有 2/9 cases 存在 dataset-level semantic target; 其中 /campaign/meta/platform 不在 gold 中。因此 A-B、B-C、C-D 的正式比较全部 non-comparable。

开发 backend 为本地 Qwen3.5 9B。两个实际 B response 都被 byte-for-byte replay 到 C；其余七个案例没有 semantic target，因而正确地不调用 B/C。表 3 是 pooled descriptive diagnostics，而非架构 effect。

表 3: 九案例合成开发诊断。B/C/D 的因果比较均不可比较。

| Variant | Comparable | 端到端准确率   | Coverage | Sel. risk | AURC     | Calls               |
|---------|------------|----------|----------|-----------|----------|---------------------|
| A       | 是          | 0.976608 | 0.988304 | 0.011834  | 0.014603 | 0                   |
| B       | 否          | 0.976608 | 0.988304 | 0.011834  | 0.014603 | 2                   |
| C       | 否          | 0.976608 | 0.988304 | 0.011834  | 0.014603 | 0 new / 2 effective |
| D       | 否          | 0.988304 | 1.000000 | 0.011696  | 0.014705 | 6                   |

B 提出一个 model claim，但未接受任何 model claim，也没有增加可评分 coverage；effective cost 为 5752 input tokens, 381 output tokens 和 4128.415 ms model latency。C 的 effective upstream cost 相同，新 generation 为零。D 提出并接受四个 claims，使用 6 calls、7538/3598 input/output tokens 与 22171.453 ms。D 在一个 hard CSV case 中恢复了两个 gold-covered logical values，但另一个改变不可评分。由于 design non-comparable，这些事实不能证明 D 更优。

Qwen3.5 在 postal-code target 上虽在 notes 中识别出语义，却最终 abstain；在无 gold coverage 的 HDF5 case 上又违反 target scope。更强模型可能在不改变 B/C 架构的情况下修复这些失败，但这只是 hypothesis。开发运行没有给出 A-B 增量，也没有给出 B-C verification trade-off。观测到的 B-C decision delta 全为零，是 uninformative contrast，而不是 verifier 没有效果的证据。

## 7 Backend Qualification

Qualification 只回答 backend 是否能执行冻结 contract，不回答 claim 是否正确。固定的非盲 calibration manifest 包含 8 个 external datasets 与 74 个 semantic targets，且不能进入未来 blind benchmark。B 在 temperature 0、seed 0 下每数据集运行两次；C 紧接每次 B 做 replay；D 按历史 policy 每数据集运行一次。

### 7.1 被作废的 8K/thinking-on 运行

首次 Qwen3.6-27B Q4\_K\_M 使用 8,192 context，而 thinking 实际仍开启。B 只有 2/16 contract-valid，D 只有 1/8 dataset runs contract-valid；12 次 B 在 generation/context boundary 截断，10,044-token 的 HDF5 prompt 在生成前被拒绝。该运行还暴露了三个 measurement defects: malformed B failure 没有把 raw identity 传到 C；unparseable output 可能被计为 target-scope valid；partial D failure 会丢失之前 group/fallback provenance。该 artifact 被不可变地标记 invalidated，任何 rate 都不用于 backend selection。

该失败作为 infrastructure diagnosis 仍有价值。LM Studio 0.4.18 的 release note 记录了某些 custom reasoning setting 下 on/off 可能被忽略的修复 [4]。本项目只修复 provenance 与 measurement，没有改 prompt、architecture、target 或 call budget。

7.2 修正后的 16K/thinking-off 运行

一次被排除在 qualification metrics 之外的 gate 先确认 contract-valid 且 reasoning tokens 为零。随后，同一 Qwen3.6-27B Q4\_K\_M 模型 [5] 在 thinking disabled、16384-token context 下通过全部冻结条件（表 4）。

表 4: 修正后的 Qwen3.6-27B operational qualification。

| 条件                            | 观测        | 要求          | 结果 |
|-------------------------------|-----------|-------------|----|
| Semantic-opportunity datasets | 8         | $\geq 8$    | 通过 |
| B contract-valid rate         | 1.0       | $\geq 0.95$ | 通过 |
| B target-scope-valid rate     | 1.0       | 1.0         | 通过 |
| B/C replay identity           | 1.0       | 1.0         | 通过 |
| B exact repeatability         | 1.0       | 1.0         | 通过 |
| B timeout / truncation        | 0.0 / 0.0 | 0.0 / 0.0   | 通过 |
| B context fit / telemetry     | 1.0 / 1.0 | 1.0 / 1.0   | 通过 |
| D contract-valid rate         | 1.0       | $\geq 0.95$ | 通过 |
| D timeout / truncation        | 0.0 / 0.0 | 0.0 / 0.0   | 通过 |
| D context fit / telemetry     | 1.0 / 1.0 | 1.0 / 1.0   | 通过 |

16 次 B 均以 JSON 和 finish\_reason=stop 结束；八个数据集的两次 response 都 byte-identical。每个 C input hash 都与 B 相同，C semantic generation count 均为零。B 最大 observed context 为 13306 tokens，最大的 input+max\_tokens request budget 为 14142，低于 loaded limit。

表 5: 修正后 qualification 的描述性 operational cost。

| 条件           | 物理调用 | Input tokens | Output tokens | 平均 latency                        |
|--------------|------|--------------|---------------|-----------------------------------|
| B（两次 repeat） | 16   | 76976        | 26436         | 27.95 s/attempt                   |
| C generation | 0    | 0 new        | 0 new         | deterministic replay/verification |
| D（一次 run）    | 59   | 79571        | 19547         | 44.61 s/dataset                   |

D 的 59 次调用来自历史调度；HDF5 case 单独需要 22 个 field calls。functional\_traits.csv 有一次 free-JSON shape failure，随后历史 schema fallback 成功。Cost gap 是事实，但 accuracy-cost trade-off 尚未被估计。

8 当前结果能够与不能证明什么

已证明的事实。 Harness 强制执行四个固定架构、精确 B/C replay、C 零 generation、fail-closed contract、显式 applicability 与 per-call telemetry。修正 runtime 后，Qwen3.6-27B

Q4\_K\_M operationally eligible。Legacy 架构在 calibration tasks 上具有显著更大的 call surface。

**未证明的内容。** 研究尚无 blind effect estimate。九案例开发集过于稀疏且 gold coverage 不完整，无法估计 A-B、B-C 或 C-D effect。Backend qualification 不读取 gold，不能证明 dataset-level reasoning 有益、verification 降低 risk、D 更准确或 Qwen 能 generalize。

**模型选择。** 当前没有 operational reason 将 Qwen3.6-27B 替换为 GLM、Llama 或更小 Qwen。其他 family 可以预声明为 sensitivity condition，但不能在看到不利架构结果后作为 post-hoc rescue，否则会把 backend selection 与 architecture effect 混淆。Model card 与精确 runtime identity 应成为一等研究 artifact [6]。

## 9 Blind External Evaluation 协议

Blind gold 将由两名未参与系统开发的 annotators 独立完成。他们必须区分 applicable value、applicable unknown、N/A 与 outside-scope slot，并在看不到 architecture output 的条件下 adjudicate disagreement。Primary analysis unit 是 paired per-dataset effect，而不是只报告 pooled slots。Development set 不作为 generalization evidence。数据集的采集、用途和限制应被显式记录 [2]。

预声明 contrasts 为：

- A-B: 新增正确/错误 claims、coverage、selective risk、unsupported claims、calls、tokens 与 latency；
- B-C: B 接受但被 C reject/abstain 的 claim、删除的错误 claim、损失的正确 claim、删除的 unsupported claim，以及 risk-coverage trade-off；
- C-D: 只有 D comparable 时，比较 quality、selective metrics、unsupported claims、calls、tokens、latency 与 failure surface。

## 9.1 Blind-freeze provenance 占位区

**停止线：** 下列字段被有意保留为空。

它们必须在 blind gold 解封前完成 content-addressing 与双人 countersign。任一字段为空都会阻止解释；不得用 development 或 qualification artifact 静默代替。

|                                                  |                     |
|--------------------------------------------------|---------------------|
| Blind sampling registration receipt              | < 盲测 GOLD 解封前必须绑定 > |
| Blind candidate-frame SHA-256                    | < 盲测 GOLD 解封前必须绑定 > |
| Blind manifest SHA-256                           | < 盲测 GOLD 解封前必须绑定 > |
| Independent annotation package SHA-256           | < 盲测 GOLD 解封前必须绑定 > |
| Adjudicated gold package SHA-256                 | < 盲测 GOLD 解封前必须绑定 > |
| Annotation vocabulary/handbook SHA-256           | < 盲测 GOLD 解封前必须绑定 > |
| Annotator pseudonyms 与 independence attestations | < 盲测 GOLD 解封前必须绑定 > |
| Calibration gate 与 agreement statistics          | < 盲测 GOLD 解封前必须绑定 > |
| Frozen backend-registry SHA-256                  | < 盲测 GOLD 解封前必须绑定 > |
| 精确 Qwen GGUF checkpoint SHA-256                  | < 盲测 GOLD 解封前必须绑定 > |
| LM Studio 0.4.18 runtime receipt SHA-256         | < 盲测 GOLD 解封前必须绑定 > |
| Frozen source commit/tree SHA-256                | < 盲测 GOLD 解封前必须绑定 > |
| Frozen analysis-plan SHA-256                     | < 盲测 GOLD 解封前必须绑定 > |
| Prompt/schema bundle SHA-256                     | < 盲测 GOLD 解封前必须绑定 > |
| Gold 解封时间与 countersignatures                     | < 盲测 GOLD 解封前必须绑定 > |

已知的 pre-freeze contract hashes 列于附录 A；它们不能替代最终 registry、checkpoint、source tree 或 gold receipt。



## 10 有效性威胁

**Construct validity.** Evidence identity 与 field relevance 不能证明 semantic entailment。C 是 deterministic trust-boundary verification，而不是 oracle。不同 property 的 confidence 可能不可比，因此需要 per-property selective curve。

**Internal validity.** B/C replay 被严格控制，但 D 有意保留 temperature 0.2 与历史 fallback。Backend state、runtime version、context、checkpoint 和 prompt hash 必须冻结。任何 partial response 或 missing replay 都会使对应 comparison 失效。

**External validity.** 九个 development cases 是 synthetic；八个 qualification cases 是已暴露给开发过程的固定 operational calibration set。两者都不是 population sample。只有未来独立标注 corpus 能支持 generalization claim。

**Statistical conclusion validity.** Blind analysis 必须报告 paired dataset-level effects 与 confidence intervals。Clean null result 完全可接受。当前 pooled metrics 只用于记录 harness behavior。

**Reproducibility.** 精确 checkpoint-file hash 和 machine-observed LM Studio version 仍缺失；0.4.18 当前是 operator-reported。这些是显式 freeze blockers，而不是隐藏 caveat。

## 11 结论

系统的持久目标仍是“输入数据集，输出 deterministic schema”，语义 enrichment 只作为 evidence-constrained optional layer。当前工作把语义架构问题收敛为四个可审计 variant，并验证了未来因果解释所需的 measurement boundary。Development data 不能为 variant 排名。修正后的 backend qualification 证明 Qwen3.6-27B 可以稳定生成一次 dataset-level response，并被 C 精确 replay 后做 deterministic verification；同时，legacy condition 暴露出远大的 call surface。

核心研究答案被有意推迟：semantic reasoning 是否增加有用 claim，以及 deterministic verification 删除的错误 claim 是否多于损失的正确 claim，只能在 blind provenance block 完成、independent gold 解封后回答。在此之前，科学上正确的结论是：协议已验证、backend operationally eligible、尚无 architecture winner。

## A 当前 Content-Addressed Artifacts

| Artifact               | SHA-256                                                          |
|------------------------|------------------------------------------------------------------|
| Development manifest   | a1a199272b9019dd99dab873239f18ba1d8b656235c54ac40ad84fb5d1738797 |
| Development report     | 1e77f66d924622153798743c209497b5025271c5d94ad4cebf6290871ff87e27 |
| Qualification manifest | 71aa69e25fddf8a3cfe9ad78e2cc2ba08015347f8ea53166985c081120fe2666 |
| Controlled vocabulary  | 874548a10f8871449be9b749c99e95e72e8852d261324abc8fa3c492246ed888 |

| Artifact                     | SHA-256                                                          |
|------------------------------|------------------------------------------------------------------|
| Invalidated 8K qualification | d0a5fb9a82d41bda557669fd384820485c5265f187679f2e954ad347eec25cde |
| Corrected qualification      | c89145cf23943fd2991504a31cea5a10ceddccc90725e31932cc02770b1c0538 |
| Qualification assessment     | bec8279af416b796d4ea5fe071a8947fcd1d7d123c1cc021168dd928fcb87efb |
| Dataset reasoner prompt      | 1b75583a35549a5cbdfecc79be5796eb358d2e5f976f5483b25756a81f8f8060 |
| Dataset response schema      | e79212874554daf93c401578b97963f45934854b22b6786ee41ae60bf8dfd7ca |
| Legacy prompt                | 3d4047f7bdc36eae832fe7e988bd06bff39be81f73bea101c6abdfc32b78a0f  |
| Legacy response schema       | 83ee4fb51579af04a304c61eb4b610263b1d02fcae1a90a56cfdb131e445a91f |

## B 当前复现状态

生成本文时, 项目 332 个 tests 全部通过; 相关 Ruff checks 通过; 316 个 JSON artifacts 全部可解析; git diff --check 通过。全树仍存在 7 个与本研究无关、此前已记录的 legacy lint findings, 本阶段未修改它们。两份 PDF 均由本 TeX source 通过 Tectonic 0.16.9 渲染 [8]。

## 参考文献

- [1] Luyu Gao, Zhuyun Dai, Panupong Pasupat, Anthony Chen, Arun Chaganty, Yicheng Fan, Vincent Zhao, Ni Lao, Hongrae Lee, Da-Cheng Juan, and Kelvin Guu. Rarr: Researching and revising what language models say, using language models. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*, pages 16477–16508, 2023.
- [2] Timnit Gebru, Jamie Morgenstern, Briana Vecchione, Jennifer Wortman Vaughan, Hanna Wallach, Hal Daumé III, and Kate Crawford. Datasheets for datasets. *Communications of the ACM*, 64(12):86–92, 2021.
- [3] Yonatan Geifman and Ran El-Yaniv. Selective classification for deep neural networks. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [4] LM Studio. Lm studio 0.4.18 release notes. <https://lmstudio.ai/changelog/lmstudio-v0.4.18>, 2026. Accessed 16 July 2026.
- [5] LM Studio. qwen/qwen3.6-27b model card. <https://lmstudio.ai/models/qwen/qwen3.6-27b>, 2026. Accessed 16 July 2026.
- [6] Margaret Mitchell, Simone Wu, Andrew Zaldivar, Parker Barnes, Lucy Vasserman, Ben Hutchinson, Elena Spitzer, Inioluwa Deborah Raji, and Timnit Gebru. Model cards for model reporting. In *Proceedings of the Conference on Fairness, Accountability, and Transparency*, pages 220–229, 2019.

- [7] Luc Moreau and Paolo Missier. Prov-dm: The prov data model. W3c recommendation, World Wide Web Consortium, 2013.
- [8] Tectonic Project. Tectonic 0.16.9. <https://github.com/tectonic-typesetting/tectonic/releases/tag/tectonic@0.16.9>, 2026. XeTeX-compatible engine used to render this manuscript.